



Universidad Nacional Autónoma de México

Facultad de Ciencias

Almacenes y minería de Datos

Reporte Final

Profesora:

★ Jessica Santizo Galicia

Ayudantes:

★ Diego Antonio Villalba González

★ Ares Gael Castro Romero

Grupo 7171

Integrantes :

★ Cano Tenorio Alan Kevin (321259967)

★ Gomez Calva Carlos Manuel (321281678)

★ Lechuga Hervert Maximiliano (321311186)

★ Vázquez Rincón Oscar (321228954)

Introducción

Problema

El proyecto analiza la distribución, concentración y evolución de la incidencia delictiva a nivel municipal y estatal en México. El problema central radica en comprender matemáticamente cómo se comportan, fluctúan y se agrupan los distintos tipos de delitos (ej. robo, homicidio, extorsión) a lo largo del territorio nacional y del tiempo.

Objetivo

Aplicar el ciclo completo de minería de datos para descubrir patrones delictivos. Se desarrollará un Análisis Exploratorio (EDA) para definir la estacionalidad, un modelo de agrupamiento (Clustering) para segmentar municipios con perfiles de riesgo similares, y un modelo supervisado para predecir tendencias criminales basadas en contexto geográfico y temporal.

Justificación y valor del proyecto

La seguridad pública es uno de los mayores retos estructurales en México. Su alta incidencia erosiona el tejido social y frena el desarrollo económico. El valor de este proyecto reside en aportar evidencia empírica sustentada en Machine Learning que exponga patrones criminales ocultos. Este conocimiento es fundamental para entender la crisis de violencia y, teóricamente, orientar la toma de decisiones y el diseño de políticas públicas preventivas.

Descripción de dataset

Los datos provienen del Secretariado Ejecutivo del Sistema Nacional de Seguridad Pública (SESNSP), obtenidos a través del portal de Datos Abiertos del Gobierno de México. El dataset supera el mínimo de 100,000 registros estipulado en los requerimientos. Cuenta con cientos de miles de registros históricos (filas) que representan las carpetas de investigación por año, además de 9 columnas útiles.

Las variables serían las siguientes:

1. Año: Variable numérica que indica el año de registro del delito

2. Bien jurídico afectado: Categoría macro que clasifica el delito según el derecho vulnerado de la víctima
3. Entidad: Variable categórica con el nombre del estado.
4. Tipo de delito: Clasificación legal específica del ilícito
5. Subtipo de delito: Desglose detallado del tipo de delito
6. Modalidad: Elemento circunstancial que detalla cómo se perpetró el acto
7. Clave_Ent: Identificador numérico oficial de dos dígitos asignado por el INEGI a cada entidad federativa
8. Mes(mes_num): Variable numérica/categórica que indica el mes de ocurrencia, fundamental para el análisis de estacionalidad.
9. Incidencia delictiva: Variable numérica continua que representa la frecuencia absoluta (conteo) de carpetas de investigación iniciadas. Funciona como el componente cuantitativo principal para los modelos analíticos.

Se utilizaron 4 variables auxiliares

1. fecha y temporal_fecha: Variables temporales estructuradas, generadas durante el preprocesamiento mediante la concatenación y conversión del año y el mes. Son utilizadas exclusivamente para construir y graficar la serie de tiempo histórica continua en el Análisis Exploratorio.
2. entidad_federativa: Variable categórica de apoyo generada como una estandarización de las etiquetas geográficas para asegurar cruces de datos limpios.
3. anio_fecha: Variable numérica auxiliar derivada del parseo temporal para optimizar la agregación de los datos (Group By) previo a la inyección en el modelo de Clustering.

Los datos reflejan únicamente los delitos denunciados que derivaron en una carpeta de investigación formal, no el total de delitos reales cometidos, que podría tener:

Errores de captura: Al ser registros consolidados por múltiples Agencias del Ministerio Público estatales, pueden existir discrepancias o retrasos en la captura.

Clasificación legal: Reflejan "presuntos delitos", por lo que el estatus legal podría cambiar durante la investigación judicial.


Limpieza y preparación de datos

Tras importar el dataset mediante la clase **DataRepository**, se confirmó que la base de datos es altamente íntegra: 0 valores faltantes y 0 registros duplicados en sus 413,952 filas. Dado que el objetivo es auditar la crisis de seguridad, se decidió no eliminar los valores atípicos (outliers), ya que en el contexto criminal, un pico anómalo no es un error de medición, sino un brote de violencia real que los modelos deben aprender a identificar.

Análisis Exploratorio

El EDA confirmó que el fenómeno delictivo no es estacionario. La serie de tiempo histórica (2015-2025) demuestra fluctuaciones regulares y caídas atípicas que coinciden con reducciones de movilidad nacional. Adicionalmente, el análisis categórico arrojó que el **36.73%** de la incidencia total corresponde al delito de "Robo", afectando mayoritariamente al "Patrimonio" el 42.86% de los casos globales.

		Porcentaje (%)
bien_juridico_afectado		
El patrimonio		42.86
La vida y la Integridad corporal		24.49
Otros bienes jurídicos afectados (del fuero co...		10.20
Libertad personal		8.16
La libertad y la seguridad sexual		7.14
La familia		4.08
La sociedad		3.06
Variable: tipo_delito Moda: Robo		
	Frecuencia Absoluta	Porcentaje (%)
tipo_delito		
Robo	152064	36.73
Homicidio	38016	9.18
Lesiones	38016	9.18
Secuestro	21120	5.10
Feminicidio	16896	4.08
Abuso de confianza	4224	1.02
Daño a la propiedad	4224	1.02
Despojo	4224	1.02
Extorsión	4224	1.02
Fraude	4224	1.02



Modelo supervisado

Se implementó un ensamble de **Random Forest Classifier** optimizado mediante búsqueda en cuadrícula (*GridSearchCV*) con validación cruzada de 5 particiones (5-fold CV). Los hiperparámetros finales fueron `n_estimators=100`, `max_depth=20` y `min_samples_split=5`.


El modelo arrojó métricas inusualmente altas. Al analizarlo, se detectó un fenómeno matemático: si al modelo se le pasa la columna `tipo_delito` para intentar predecir el `bien_juridico_afectado`, el algoritmo sufre de **Data Leakage**, ya que existe un mapeo administrativo directo entre ambas. Para predecir el futuro genuinamente, el modelo debe entrenarse aislando los componentes temporales y geográficos.


Clustering

Para el modelo no supervisado, se consolidó el perfil delictivo transformando el dataset en una matriz pivote (32 entidades × 40 tipos de delito). Se escalaron los datos y se aplicó una reducción de dimensionalidad que logró capturar el **64.20%** de la varianza original en solo 2 componentes principales. Posteriormente, se ejecutó un algoritmo **K-Means**, el cual fue validado exitosamente utilizando el Coeficiente de Silueta y el Índice Davies-Bouldin para garantizar la cohesión matemática de los grupos de riesgo estatal.

Se ejecutó el algoritmo K-Means evaluando múltiples particiones. Utilizando el **Método del Codo**, se observó un quiebre geométrico y la estabilización de la inercia (SSE) en **k=4**. Esta decisión se validó rigurosamente mediante el Coeficiente de Silueta, el cual arrojó un score de **0.3880**, confirmando que los datos poseen una densidad de agrupación razonable sin solapamientos severos, y un Índice Davies-Bouldin de 0.9577 que garantiza la cohesión de los grupos. El algoritmo logró segmentar a las 32 entidades federativas en 4 clústeres que comparten "firmas delictivas" estructurales:

- **Cluster 1 (Alta Incidencia Patrimonial):** Agrupa a las entidades que concentran magnitudes masivas y picos atípicos en delitos de robo (en todas sus modalidades) y fraude.
- **Cluster 2 (Alta Violencia):** Segmenta a los estados que, independientemente de su tamaño, registran densidades alarmantemente elevadas en delitos de impacto directo (homicidios y lesiones).
- **Clústeres 0 y 3 (Incidencia Media y Dinámicas Locales):** Agrupan al resto de las entidades que se posicionan en escalas de incidencia media a baja, diferenciándose sutilmente por dinámicas regionales específicas (como narcomenudeo o violencia intrafamiliar).







Arquitectura y diseño

El código fuente del proyecto fue desarrollado íntegramente bajo el paradigma de Programación Orientada a Objetos (POO), garantizando modularidad, encapsulamiento y alta cohesión. Para resolver los distintos retos del ciclo de vida de los datos, se implementaron múltiples Patrones de Diseño de Software:

- **Patrón Factory Method** (model_factory.py): Se implementó mediante la clase estática ModelRegistry y las interfaces ModelFactory.
 - Utilizar este patrón nos permitió instanciar diferentes modelos matemáticos (Random Forest, SVM, Regresión Logística, etc.) de manera dinámica e intercambiable. Al abstraer la creación de los objetos, el código cliente (los notebooks) puede iterar entre algoritmos sin necesidad de alterar su lógica interna.
- **Patrón Pipeline y Strategy** (pipeline.py): Se construyó la clase DataPipeline que orquesta secuencialmente las etapas de procesamiento, apoyada por la interfaz CleaningStrategy.
 - El patrón **Pipeline** fue idóneo dado que el procesamiento de datos requería etapas cronológicas estrictas. En paralelo, el patrón **Strategy** permitió intercambiar dinámicamente las reglas de negocio en tiempo de ejecución.

- **Patrón Repository** (data_repository.py): Se definió a través de la interfaz BaseRepository y sus implementaciones concretas.
 - Se deseaba abstraer completamente el acceso a disco (archivos CSV) detrás de una interfaz uniforme. Este encapsulamiento previno que la lógica de modelado interactuara directamente con rutas de sistema locales, dotando al proyecto de reproducibilidad universal en cualquier entorno.
- **Clases Utilitarias** (evaluator.py): Se encapsuló la lógica de evaluación gráfica y de métricas (MAE, MSE, F1-Score, AUC-ROC) en una clase independiente, aislando la visualización matemática del entrenamiento del algoritmo.



Reutilización del modelo

Se comprobó el desacoplamiento del sistema. El estimador entrenado fue exportado físicamente utilizando la librería joblib (.joblib). Se creó un script secundario de demostración (04_demo_reutilizacion.ipynb) capaz de importar este binario opaco y generar predicciones instantáneas sobre vectores numéricos sintéticos, sin ejecutar ni una sola línea de la fase de entrenamiento.

Conclusiones

Al aplicar lo aprendido a lo largo del curso se pudo auditar el panorama de seguridad pública en México, el fenómeno delictivo no es estacionario. Responde fuertemente a dinámicas temporales y está dominado abrumadoramente por los delitos contra el patrimonio, donde el "Robo" representa el 36.73% de la carga delictiva nacional. A través de la reducción de dimensionalidad (PCA) y el algoritmo K-Means, se logró agrupar a las 32 entidades federativas en perfiles de riesgo cohesivos. Donde los estados comparten "firmas delictivas" medibles, lo cual es invaluable para diseñar estrategias de seguridad focalizadas por región y no generalizadas. : El algoritmo de Random Forest alcanzó métricas de rendimiento inusualmente altas. Sin embargo, el análisis crítico del modelo reveló que esto se debe a un fenómeno de *Data Leakage* institucional: existe un mapeo determinista entre el "Tipo de delito" y el "Bien jurídico afectado". La máquina aprendió a descifrar la estructura burocrática del sistema de justicia en lugar de la dinámica criminal cruda. Para lograr inferencias puras, el modelo demostró que debe entrenarse aislando exclusivamente los componentes de tiempo y geografía.

La barrera analítica más significativa del proyecto es la "cifra negra". Dado que el modelo se alimentó exclusivamente de carpetas de investigación formalizadas, las predicciones y agrupamientos reflejan únicamente la capacidad de denuncia y respuesta institucional de cada estado, ignorando el volumen de delitos reales no reportados. Asimismo, la agregación de datos a nivel estatal invisibiliza las micro-dinámicas criminales que ocurren a nivel municipal.

Para un futuro y para poder escalar la solución, se propone lo siguiente:

1. Cruzar la base de datos de incidencia delictiva con indicadores socioeconómicos externos (como índices de pobreza del CONEVAL o densidad poblacional del INEGI) para que los algoritmos puedan identificar las causas estructurales del crimen.
2. Evolucionar el modelo de clasificación a arquitecturas especializadas en secuencias temporales para predecir fluctuaciones futuras exactas en el volumen de carpetas de investigación.
3. Adaptar la clase **DataRepository** para ingestar y procesar el dataset a nivel municipal, permitiendo un nivel de detalle que optimice la asignación de recursos policiales en las calles.

Referencias

- Secretariado Ejecutivo del Sistema Nacional de Seguridad Pública [SESNSP]. (2025, 13 marzo). Incidencia delictiva. Gobierno de México. https://www.datos.gob.mx/dataset/incidencia_delictiva
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.
- McKinney, W. (2010). Data Structures for Statistical Computing in Python. En *Proceedings of the 9th Python in Science Conference* (pp. 51-56). Austin, TX.
- Instituto Nacional de Estadística y Geografía [INEGI]. (2023). *Encuesta Nacional de Victimización y Percepción sobre Seguridad Pública (ENVIPE) 2023*. Recuperado de <https://www.inegi.org.mx/programas/envipe/2023/>
- Gamma, E., Helm, R., Johnson, R., & Vlissides, J. (1994). *Design Patterns: Elements of Reusable Object-Oriented Software*. Addison-Wesley Professional.